Assignment-06

A1.

Токен	Вектор
dog	[1, 0, 1]
bites	[0, 2, 0]
man	[1, 0, -1]
movie	[0, 1, 1]
good	[2, 1, 0]
not	[-2, 0, 0]

1. "dog bites man"

Sum: $[1+0+1,\ 0+2+0,\ 1+0+(-1)] = [2, 2, 0]$

Average: $[\frac{2}{3}, \frac{2}{3}, 0]$

2. "man bites dog"

Sum: $[1+0+1,\ 0+2+0,\ 1+0+1] = [2, 2, 0]$

Average: $[\frac{2}{3}, \frac{2}{3}, 0]$

$[1+0+1,\ 0+2+0,\ -1+0+1] = [2, 2, 0]$

3. "movie good"

Sum: $[0+2, 1+1, 1+0] = [2, 2, 1]$

Average: $[2, 1, \frac{1}{2}]$

4. "movie not good"

Average: $[0, \frac{2}{3}, \frac{1}{3}]$

Sum: $[0+(-2)+2, 1+0+1, 1+0+0] = [0, 2, 1]$

A2. Расчеты

1. "dog bites man" и "man bites dog"

$[\frac{2}{3}, \frac{2}{3}, 0]$ и $[\frac{2}{3}, \frac{2}{3}, 0]$

Какая пара имеет одинаковый вектор, несмотря на разный смысл?

dog bites man → собака укусила человека.

man bites dog → человек укусил собаку.

Но смысл разный

2. Какая пара имеет похожую тему, но разный посыл?

"movie good" и "movie not good"

Оба предложения про фильм

Но, movie good → положительное мнение

movie not good → отрицательное мнение

3. Что это говорит вам о представлениях слов в виде мешка слов или усредненных векторных представлений?

Усреднение векторов слов игнорирует порядок слов и контекст, поэтому предложения с разным смыслом могут иметь одинаковое представление. Также модель плохо учитывает отрицание, из-за чего смысл может искажаться.

А3. Усреднение векторных представлений слов может быть полезным для задач, где важна общая тема текста, например, классификация настроения или поиск похожих документов.

Такой метод прост и быстро работает даже на небольших данных. Однако он не учитывает порядок слов и синтаксическую структуру предложения. Из-за этого предложения с одинаковыми словами, но разным порядком могут иметь одинаковые векторы.

Также модель плохо обрабатывает отрицание, например слова "not good" могут быть неправильно интерпретированы. Эти ограничения показывают необходимость использования моделей, которые учитывают последовательность слов, таких как RNN, LSTM и GRU.